

Calidad De Requisitos Funcionales Elicitados Por Un Equipo Humano Frente A Los Generados Por Un Modelo De Lenguaje Grande: Un Estudio De Caso En La Gestión Inteligente De Aulas Universitarias



This is an update to the original registration. This update was made on Aug 27, 2026.

Reason for update:

Se documentan 9 desviaciones respecto del plan pre-registrado, detectadas durante la ejecución del componente empírico entre el 02/08/2026 y el 13/08/2026: 1. Exclusión de la entrevista EV-15 (código DOC-03) del corpus humano por retiro de consentimiento informado del participante (13/08/2026). 2. El corpus fuente que procesó el modelo de lenguaje (Conjunto A) ya incluía EV-15 antes de su exclusión, y ya había sido evaluado por los tres jueces ciegos; no fue posible re-ejecutar el experimento completo por restricción de tiempo. 3. Cierre del levantamiento de campo en N=10 entrevistas en lugar de $N \geq 16$, autorizado verbalmente por el docente responsable por restricción de calendario. 4. Intervalos de confianza al 95% por bootstrap (10 000 réplicas) para los tamaños del efecto: el plan pre-registrado especificaba reportar d de Cohen / delta de Cliff sin intervalos de confianza. 5. Prueba de Levene para homogeneidad de varianzas,

añadida junto a Shapiro-Wilk, no contemplada en el plan pre-registrado. 6. Número final de jueces (3): el plan pre-registrado establecía un mínimo de 3 y recomendaba 5; se ejecutó con el mínimo. 7. Exposición previa del modelo al Conjunto B dentro de la misma cuenta de chat, amenaza a la validez de constructo. 8. Asimetría de corpus resultante de los puntos 1-2: el conjunto LLM se generó sobre 11 entrevistas, el conjunto humano quedó respaldado por 10. 9. El criterio de saturación temática se cerró mediante cálculo de potencia estadística en lugar de la curva de saturación pre-registrada, porque la codificación abierta no pasó por una fase de codificación axial. El detalle completo de cada desviación (razón, momento de detección y mitigación aplicada) consta en el documento adjunto [osf_deviations.pdf](#) (versión corregida). Ninguna desviación buscó ni produjo un resultado significativo: los ajustes del plan de análisis (bootstrap, Levene) son más conservadores, no menos, y de hecho ninguna de las 5 dimensiones evaluadas resultó significativa tras aplicar la corrección de Holm-Bonferroni, que sí formaba parte del plan original.



Data



Analytic Code



Materials



Papers



Supplements

Public registration



Updates



Overview

Research questions or hypotheses

H0: No hay diferencia significativa en la puntuación media de calidad entre el Conjunto A (LLM) y el Conjunto B (humano) en ninguna de las 5 dimensiones evaluadas.
H1: Existe una diferencia significativa en la puntuación media de calidad entre el Conjunto A y el Conjunto B en al menos una dimensión.

Foreknowledge of data or evidence

Updated

Analyses in this plan have been conducted already. At least some of the analyses described in this analysis plan have been conducted by the authors making this a retrospective registration.

Explanation of foreknowledge and managing unintended influences

Updated

Esta actualización del registro se presenta después de ejecutar el plan de análisis pre-registrado y de conocer los resultados, con el único propósito de declarar explícitamente las desviaciones detectadas durante esa ejecución (ver Justification). Ninguna de las desviaciones al plan de análisis (corrección de Holm-Bonferroni, intervalos de confianza por bootstrap, prueba de Levene) fue decidida después de ver qué resultado producía cada una: las tres hacen el análisis más conservador, no menos, y de hecho ninguna de las 5 dimensiones evaluadas resultó significativa una vez aplicadas. La exclusión de la entrevista EV-15 respondió a un retiro de consentimiento informado del participante, no a un criterio estadístico. El cierre del criterio de saturación temática mediante cálculo de potencia, en lugar de la curva de saturación, respondió a una limitación del codebook (sin fase de codificación axial), detectada al ejecutar el pipeline, no a una decisión posterior a observar el resultado deseado.

Research Design

Study type

Non-randomized study: Does not include random assignment of subjects to treatments or conditions. This usually includes correlational studies, observational studies, surveys, natural experiments, real-world evidence studies, regression discontinuity designs, and descriptive studies.

Intention for causal interpretation

No causal relationship inferred: This study is not intended to inform a causal relationship.

Blinding of experimental treatments

Researchers or observers who code or interpret data for analysis will not be aware of the assigned treatments during coding.

Additional blinding during research or analysis

No data

Study design

Este estudio sigue un diseño cuasi-experimental por pares para comparar la calidad de los requisitos funcionales obtenidos por un equipo humano de ingeniería de requisitos y los generados por un modelo de lenguaje a gran escala (LLM) a partir de los mismos materiales de origen. Los materiales de origen consisten en entrevistas, cuestionarios, observaciones e información contextual recopilada durante el proceso de obtención de requisitos para el Sistema Inteligente de Gestión del Aula (SIGA).

Se elaborarán dos conjuntos de requisitos: el conjunto A (requisitos generados por el LLM) y el conjunto B (requisitos generados por personas). Ambos conjuntos se derivarán de la misma evidencia de obtención. Los requisitos se anonimizarán y se presentarán a evaluadores independientes utilizando identificadores neutros para evitar el reconocimiento de la fuente.

Los evaluadores valorarán cada conjunto de requisitos en función de cinco dimensiones de calidad predefinidas. Dado que se utiliza la misma información de origen para generar ambos conjuntos de requisitos, la comparación es por pares (diseño

intrasujeto). No se realizará ninguna asignación aleatoria de los participantes a los tratamientos.

Para reducir el sesgo de evaluación, se ocultará a los evaluadores el origen de los requisitos durante el proceso de valoración. Los análisis estadísticos compararán las puntuaciones de calidad obtenidas por ambos conjuntos de requisitos en las dimensiones evaluadas.

No files selected

Randomization

No data

Sampling

Data collection procedures

El estudio se llevará a cabo en la Facultad de Informática y Diseño Digital de la Universidad Técnica Estatal de Quevedo (UTEQ), en Ecuador. Los datos se recopilarán de miembros adultos voluntarios de la comunidad universitaria, entre los que se incluyen coordinadores académicos, profesores, personal administrativo y estudiantes que participan en los procesos de gestión de las aulas.

Los participantes serán seleccionados mediante invitaciones institucionales y participación voluntaria. Los criterios de inclusión son tener al menos 18 años y poseer conocimientos, experiencia o interacción relacionados con el uso de las aulas, la programación de horarios, el mantenimiento o las actividades académicas. Se excluirá a aquellas personas que no den su consentimiento informado o cuya participación sea incompleta.

Los datos para la determinación de requisitos se recopilarán mediante entrevistas semiestructuradas, cuestionarios digitales y observación directa. La información recopilada se anonimizará y se consolidará en un conjunto de datos de origen común.

A continuación, se elaborarán dos conjuntos de requisitos funcionales a partir del mismo material de origen: uno generado por un equipo humano de ingeniería de requisitos y otro generado por un modelo de lenguaje a

gran escala (LLM). Ambos conjuntos serán evaluados de forma independiente por evaluadores ciegos utilizando una rúbrica de evaluación de calidad predefinida. Se prevé que la recopilación de datos tenga lugar durante la fase de ingeniería de requisitos del proyecto SIGA. No se publicará ni divulgará ninguna información de carácter personal.

Data collection procedures - File upload

No files selected

Sample size

El estudio empírico evaluará 51 requisitos funcionales, de los cuales 26 han sido generados por un modelo de lenguaje a gran escala (LLM) y 25 han sido recabados por un equipo humano de ingeniería de requisitos. Ambos conjuntos de requisitos se han elaborado a partir del mismo material de origen, que incluye entrevistas semiestructuradas, cuestionarios digitales, observación directa e información contextual del ámbito de aplicación.

Cada requisito será evaluado de forma independiente por al menos tres evaluadores expertos, que valorarán cada requisito en función de cinco dimensiones de calidad predefinidas: exhaustividad, ausencia de ambigüedad, verificabilidad, corrección con respecto a la fuente y coherencia interna.

Por consiguiente, el conjunto de datos mínimo previsto comprenderá 51 requisitos evaluados $\times$ 3 jueces = 153 registros de evaluación, con cinco puntuaciones de calidad registradas para cada evaluación. Si se dispone de jueces cualificados adicionales antes de que finalice la recopilación de datos, sus evaluaciones se incorporarán siguiendo el mismo protocolo.

Sample size rationale

El tamaño de la muestra viene determinado por la disponibilidad del conjunto completo de requisitos funcionales generados durante el estudio de caso SIGA, y no por un muestreo aleatorio. Por lo tanto, se incluirán en el análisis todos los requisitos funcionales elegibles generados mediante ambos enfoques de obtención.

Se estableció un mínimo de tres evaluadores expertos independientes para permitir la estimación de la concordancia entre evaluadores (κ de Cohen y κ de Fleiss) y para reducir el sesgo individual de los evaluadores. Este umbral se adopta habitualmente en estudios empíricos de ingeniería de software que emplean la evaluación de expertos.

La potencia estadística se evaluará antes de la comprobación de hipótesis, siguiendo el plan de análisis preregistrado ($\alpha = 0,05$, potencia deseada = 0,80). Dado que el estudio analiza la población completa de requisitos generados para el estudio de caso, no se llevará a cabo ningún procedimiento de muestreo adicional.

Starting and stopping rules

La recogida de datos no comenzará hasta que se haya completado el preregistro en la OSF y se haya distribuido el paquete de evaluación ciega a los jueces participantes.

Cada juez evaluará de forma independiente el conjunto completo de 51 requisitos anonimizados utilizando la rúbrica de evaluación predefinida. Los jueces mantendrán el anonimato respecto al origen de cada requisito a lo largo de todo el proceso de evaluación.

La recogida de datos concluirá cuando:

todos los jueces reclutados hayan enviado los formularios de evaluación completos; o se haya obtenido la muestra mínima prevista de tres evaluaciones completas de los jueces y haya expirado el periodo de recogida de datos predefinido.

No se llevarán a cabo análisis intermedios, pruebas de hipótesis secuenciales, interrupciones opcionales ni procedimientos de muestreo adaptativo. No se añadirán requisitos adicionales una vez que haya comenzado la recogida de datos. Cualquier formulario de evaluación incompleto se tratará de acuerdo con la estrategia de datos faltantes preregistrada.

Variables

Manipulated variables

Ninguna. Este estudio no incluye variables manipuladas ni grupos de tratamiento aleatorizados. Se trata de un estudio cuasi-experimental por pares en el que se comparan dos conjuntos preexistentes de requisitos funcionales (generados por un modelo de lenguaje grande [LLM] y obtenidos de personas) evaluados en condiciones idénticas por un grupo de expertos que desconocían los datos.

No files selected

Measured variables

Las principales variables medidas son las puntuaciones de calidad asignadas por los jueces expertos, que evalúan de forma ciega, a cada requisito funcional.

Cada requisito se evaluará de forma independiente en las siguientes cinco dimensiones de calidad, utilizando una escala ordinal de cinco puntos (1 = calidad más baja, 5 = calidad más alta):

Exhaustividad
Ausencia de ambigüedad
Verificabilidad
Corrección con respecto al material de origen
Coherencia interna

Entre las variables registradas adicionales se incluyen:

Origen del requisito (generado por un modelo de lenguaje grande [LLM] u obtenido por personas).
Identificador del requisito (código anónimo del elemento).
Identificador del evaluador (código anónimo del evaluador).

Las puntuaciones de calidad constituyen las medidas de resultado principales. El origen del requisito es la variable de agrupación independiente utilizada para la comparación. Los identificadores del evaluador y del requisito se utilizarán para organizar las observaciones emparejadas y evaluar la

concordancia entre evaluadores, pero no se tratarán como variables de resultado.

Measured variables - File upload

No files selected

Indices

Para cada requisito funcional, se conservará de forma individual la puntuación asignada por cada evaluador. Además, se calcularán las siguientes variables derivadas:

1. Puntuación media por dimensión: la media aritmética de las puntuaciones de los evaluadores para cada dimensión de calidad.

$$\bar{x} \text{ dimension} = \sum_{i=1}^n x_i / n$$

donde x_i es la puntuación asignada por el evaluador i y n es el número de evaluadores.

2. Puntuación global de calidad: la media aritmética de las puntuaciones medias de las cinco dimensiones para cada requisito.

Overall Quality = Exhaustividad + Ambigüedad + Verificabilidad + Corrección + Coherencia / 5

These derived variables will be used for descriptive analyses. Inferential statistical analyses will primarily compare the two requirement groups using the individual quality dimensions as specified in the preregistered analysis plan.

Indices - File upload

No files selected

Analysis Plan

Statistical models **Updated**

El objetivo principal es comparar la calidad de los requisitos funcionales generados por un modelo de lenguaje a gran escala (LLM) con los obtenidos por un equipo humano de ingeniería de requisitos.

Se llevarán a cabo cinco pruebas de hipótesis

independientes, una para cada dimensión de calidad:

- Exhaustividad
- Ausencia de ambigüedad
- Verificabilidad
- Corrección con respecto al material de origen
- Coherencia interna

Para cada dimensión, se compararán las puntuaciones medias asignadas por los evaluadores ciegos a los dos grupos de requisitos (generados por el LLM frente a los obtenidos por humanos).

Antes de realizar las pruebas de hipótesis, se evaluará la distribución de las puntuaciones para cada dimensión mediante la prueba de normalidad de Shapiro-Wilk.

- Si no se rechaza la hipótesis de normalidad ($p \geq 0,05$), se utilizará una prueba t de Student para datos emparejados.
- En caso contrario, se aplicará la prueba de rangos con signo de Wilcoxon.

Los tamaños del efecto se expresarán como la d de Cohen para los análisis paramétricos y como el delta de Cliff para los análisis no paramétricos.

La fiabilidad interevaluador se evaluará antes de los análisis principales utilizando el κ de Cohen para cada par de evaluadores y el κ de Fleiss para el panel completo de evaluadores.

No se han previsto términos de interacción, modelos de regresión, análisis de subgrupos ni pruebas ómnibus.

ACTUALIZACIÓN RETROSPECTIVA: se añadieron dos elementos no contemplados en este plan original: (1) intervalos de confianza al 95% por bootstrap (10 000 réplicas, semilla 20260802) junto a los tamaños del efecto reportados arriba; (2) la prueba de Levene para homogeneidad de varianzas, aplicada junto a Shapiro-Wilk antes de elegir entre prueba t o Wilcoxon. Ambos ajustes hacen el análisis más conservador, no menos.

Statistical models - File upload

No files selected

Transformations

El origen de los requisitos se tratará como una variable categórica binaria con dos niveles:

0 = Requisitos formulados por personas
1 = Requisitos generados por un modelo de lenguaje grande (LLM)

Las puntuaciones de calidad se mantendrán en su escala ordinal original de cinco puntos (1-5). No está previsto realizar ningún centrado, normalización, escalado, recodificación ni transformación matemática de las puntuaciones de calidad antes del análisis estadístico.

Inference criteria

La significación estadística se evaluará utilizando un nivel de significación de $\alpha = 0,05$.

Todas las pruebas de hipótesis serán bilaterales, ya que el estudio tiene como objetivo detectar cualquier diferencia estadísticamente significativa entre las dos fuentes de requisitos sin dar por sentada la superioridad de ninguno de los dos enfoques.

Dado que se llevarán a cabo cinco pruebas de hipótesis independientes (una por cada dimensión de calidad), se aplicará la corrección de Holm-Bonferroni para controlar la tasa de error familiar.

Además de los valores p , se indicarán los tamaños del efecto y los intervalos de confianza del 95 % siempre que sea aplicable.

Data inclusion and exclusion

Se incluirán en los análisis todos los requisitos funcionales generados durante el estudio y que cumplan los criterios de elegibilidad predefinidos.

Un requisito solo se excluirá si:

- es un duplicado
- se generó al margen del proceso de obtención predefinido;
- no puede evaluarse debido a que el texto está incompleto o dañado.

Las evaluaciones de los jueces solo se incluirán si se ha enviado el formulario de evaluación completo.

No se llevará a cabo ninguna eliminación de valores atípicos estadísticos, ya que las puntuaciones de calidad se recogen en una escala ordinal acotada (1-5), en la que los valores extremos representan juicios válidos de los expertos y no errores de medición.

Missing data

Las puntuaciones que falten no se imputarán.

Si un evaluador omite una o más puntuaciones para un requisito, los análisis que incluyan dichas observaciones utilizarán únicamente los datos disponibles.

Los requisitos con datos insuficientes para realizar los análisis previstos se excluirán únicamente del análisis en cuestión, pero seguirán estando disponibles para aquellos análisis en los que existan datos completos.

El número de observaciones que falten y las posibles exclusiones se indicarán de forma transparente en el estudio final.

Other planned analysis

Como análisis secundarios, se presentarán estadísticas descriptivas (media, mediana, desviación estándar y rango intercuartílico) para cada dimensión de calidad y cada grupo de requisitos.

También se presentarán estadísticas de concordancia entre evaluadores (κ de Cohen y κ de Fleiss) para evaluar la coherencia de las evaluaciones de los evaluadores.

No se prevén pruebas de hipótesis exploratorias adicionales más allá de las especificadas en este registro previo.

Other

Context and additional information

Updated

Este estudio forma parte del proyecto de investigación SIGA (Sistema Inteligente de Gestión de Aulas), desarrollado en la Universidad Técnica Estatal de Quevedo (UTEQ). El sistema integra tecnologías del Internet de las cosas (IoT) e inteligencia artificial para facilitar la supervisión y la gestión de las aulas universitarias.

Ambos conjuntos de requisitos funcionales se generaron a partir de las mismas fuentes de evidencia, entre las que se incluyen entrevistas semiestructuradas, cuestionarios digitales, observación directa e información contextual del ámbito. El equipo humano de ingeniería de requisitos y el Modelo de Lenguaje a Gran Escala (LLM) trabajaron de forma independiente utilizando el mismo material de origen.

Para minimizar el sesgo en la evaluación, todos los requisitos se anonimizarán y se presentarán en orden aleatorio. Los jueces expertos desconocerán el origen de cada requisito a lo largo de todo el proceso de evaluación y evaluarán de forma independiente cada uno de ellos utilizando una rúbrica de calidad predefinida.

El protocolo de investigación completo, la rúbrica de evaluación y el paquete de evaluación ciega se han archivado en el proyecto OSF para facilitar la transparencia, la reproducibilidad y la futura replicación del estudio. Cualquier desviación respecto a este registro previo se documentará y justificará explícitamente en publicaciones posteriores.

ACTUALIZACIÓN RETROSPECTIVA
(13/08/2026): la afirmación de "mismo material de origen" del segundo párrafo describe el diseño planeado. En la ejecución real, una de las entrevistas (EV-15, código de participante DOC-03) fue excluida del corpus humano por retiro de consentimiento informado, después de que el LLM ya había procesado esa entrevista para generar el Conjunto A y

después de que los tres jueces ciegos ya habían evaluado ese conjunto. En consecuencia, el Conjunto A se generó sobre 11 entrevistas y el Conjunto B quedó respaldado por 10; esta asimetría se declara como amenaza a la validez de constructo. El detalle completo de esta y las demás desviaciones consta en [osf_deviations.pdf](#), archivado en este mismo proyecto OSF exactamente el compromiso de documentación explícita que ya declaraba el párrafo anterior.

Metadata

Contributors

[Sánchez Gary](#),
[Winston Damian Cedeño Avila](#),
[ALLAN JEREMY MENDOZA PALMA](#),
[Yeranick Esther](#)

Resource Type

No resource type

Description

SIGA es un sistema de gestión inteligente de aulas basado en IoT e Inteligencia Artificial, desarrollado para la Facultad de Ciencias d... la Computación y Diseño Digital de la UTEQ.

[Read more](#) tiene un doble objetivo: especificar formalmente los requisitos del sistema mediante entrevistas, cuestionarios y personal de coordinación, docentes, personal administrativo y estudiantes voluntarios; y ejecutar un componente empírico que compara la

Registration Type

OSF Preregistration

Registry

OSF Registries
frente. La población participante son adultos voluntarios de la propia comunidad UTEQ

Date Created

Aug 2, 2026, 3:25 PM

Date Registered

Aug 2, 2026, 3:25 PM

Metodo combina entrevistas semiestructuradas, cuestionario digital, observación directa y validación por

Subjects

Engineering

Other Engineering

Education

Tags

No tags

Affiliated Institutions

No affiliated institutions

Funder Names

No information

Language

No language

Associated Project

<https://osf.io/3nruf>

Internet Archive Link

<https://archive.org/details/osf-registrations-7pq3h-v1>

License

CC-BY Attribution-NonCommercial 4.0
International

Registration DOI



Center for Open Science

[Terms of Use](#) | [Privacy Policy](#) | [Status](#) | [API](#) |
[TOP Guidelines](#)

Copyright © 2011-2025