

Protocolo del componente empírico

Proyecto SIGA — Sistema Inteligente de Gestión de Aulas

Ingeniería de Requerimientos [20303] — Equipo FGMMN
Facultad de Ciencias de la Computación, UTEQ

Versión 2.0 — 3 de agosto de 2026

Enfoque

Comparación de calidad de requisitos funcionales elicitados por un equipo humano frente a los generados por un modelo de lenguaje grande (LLM) a partir del mismo material fuente.

1. Marco PICOC

Elemento	Definición
Población	Requisitos funcionales del sistema SIGA (26 generados por LLM, 25 elicitados por el equipo humano).
Intervención	Elicitación asistida por modelo de lenguaje grande, a partir del corpus completo de 11 entrevistas anonimizadas.
Comparación	Elicitación tradicional por el equipo humano (entrevistas y análisis manual).
Resultado	Puntuación de calidad en 5 dimensiones: completitud, ausencia de ambigüedad, verificabilidad, corrección respecto de la fuente y consistencia interna; evaluada por al menos 3 jueces ciegos.
Contexto	Proyecto académico de Ingeniería de Requerimientos, dominio de gestión inteligente de aulas, FCCDD, UTEQ.

2. Pregunta de investigación

¿En qué dimensiones de calidad los requisitos funcionales elicitados por un equipo humano difieren de los generados por un modelo de lenguaje grande a partir del mismo material fuente?

3. Hipótesis

- **H₀**: No hay diferencia significativa en la puntuación media de calidad entre el Conjunto A (LLM) y el Conjunto B (humano) en ninguna de las 5 dimensiones evaluadas.
- **H₁**: Existe una diferencia significativa en la puntuación media de calidad entre el Conjunto A y el Conjunto B en al menos una dimensión.

4. Variables

Tipo	Variable
Independiente	Origen del requisito (Humano / LLM).
Dependientes	Puntuación de 1 a 5 en cada una de las 5 dimensiones de la rúbrica.
Control	Mismo material fuente para ambos conjuntos; los mismos jueces evalúan ambos conjuntos; orden aleatorizado y ciego.

5. Participantes (jueces evaluadores)

Requisito de independencia: ninguno de los jueces puede ser una de las personas entrevistadas en las 11 transcripciones que sirvieron como material fuente (DOC-01 a DOC-04, COORD-01 a COORD-03, CONS-01 a CONS-04), para preservar la ceguera del diseño. Se exige un mínimo de 3 jueces; se recomiendan 5 cuando sea posible, conforme a la Sección 5.1 de la guía.

Cada juez firmó un consentimiento informado específico, archivado en `06_Experimento/instrumentos/`.

6. Diseño

Cuasi-experimento apareado. Cada juez evalúa los 51 ítems del paquete ciego (`Paquete_Evaluacion_Ciega_J`) sin conocer el origen de cada uno, usando la `Hoja_Puntuacion_JUEZ.csv`. El orden fue aleatorizado con semilla fija (20260802) para garantizar reproducibilidad.

7. Plan de análisis estadístico

1. Consolidar las hojas de puntuación de los jueces.
2. Calcular el acuerdo inter-evaluador: κ de Cohen por par de jueces y κ de Fleiss para el conjunto completo.
3. Prueba de normalidad de Shapiro-Wilk sobre las puntuaciones de cada conjunto, por dimensión.
4. Si los datos son normales, prueba t para muestras apareadas comparando la media de cada juez en el Conjunto A frente al Conjunto B. Si no lo son, prueba de Wilcoxon.
5. Tamaño del efecto: d de Cohen en el caso paramétrico, δ de Cliff en el no paramétrico.
6. Cálculo de potencia estadística previo, con $\alpha = 0,05$ y potencia deseada $1 - \beta = 0,80$.

Los scripts que reproducen estas tablas a partir de los datos crudos se encuentran en `06_Experimento/script`

8. Amenazas a la validez

- **Validez de constructo:** el modelo usado para generar el Conjunto A tuvo exposición previa parcial al Conjunto B dentro de la misma cuenta de chat. La limitación se documenta en detalle en `prompt_llm_conjunto_A.md`.
- **Validez interna:** los jueces deben ser verificablemente independientes de las 11 entrevistas fuente; su selección queda documentada.
- **Validez externa:** los resultados son específicos del dominio SIGA y de un modelo de LLM particular; no se generalizan automáticamente a otros dominios ni a otros modelos.
- **Validez de conclusión:** el tamaño de muestra (51 ítems, 3 jueces) es modesto. Se recomienda ampliar el número de jueces hacia la Entrega 4 (2B) si el tiempo lo permite.

9. Registro previo del protocolo

El protocolo está registrado en el Marco de Ciencia Abierta (OSF):

<https://osf.io/3nruf/>

Nota de actualización, 2026-09-02. El texto de este protocolo se conserva tal como se registró y no se reescribe. Dos datos han cambiado desde entonces y se consignan aquí sin alterar el original. Primero, el enlace de arriba apunta al *nodo de proyecto 3nruf*, que es mutable; el registro congelado, que es el que tiene DOI y el que debe citarse, es <https://doi.org/10.17605/OSF.IO/7PQ3H> (<https://osf.io/7pq3h>). Segundo, el estado que se declara a continuación quedó superado: el registro fue **aceptado el 2026-08-02**, y el 2026-08-27 se le añadieron las nueve desviaciones. El detalle consta en `06_Experimento/registro_previo/registro_osf.md`.

Estado actual: *Pending registration approval*. El registro fue enviado antes de la distribución del paquete ciego a los jueces, conforme al gatekeeper G6 de la guía. La aprobación por parte de OSF es un trámite administrativo posterior al envío y no altera la fecha de registro, que es la que otorga la precedencia temporal.

10. Disponibilidad de datos y materiales

El conjunto de datos anonimizado está depositado en Zenodo bajo licencia Creative Commons Atribución 4.0 Internacional (CC BY 4.0):

<https://doi.org/10.5281/zenodo.21774351>

Nota de actualización, 2026-09-02. El depósito citado arriba corresponde al estado del paquete cuando se registró el protocolo. El depósito vigente de la Entrega Final, que es el declarado en `CITATION.cff` y el que acompaña al manuscrito, es <https://doi.org/10.5281/zenodo.22663649>.

Los datos identificables (grabaciones de audio y video, consentimientos con cédula y firma visibles) permanecen en la zona restringida del repositorio, cifrada con AES-256, conforme a la Sección 4.1 de la guía y a la Ley Orgánica de Protección de Datos Personales del Ecuador.