

SIGA — Sistema Inteligente de Gestión de Aulas

Human-Elicited vs. LLM-Generated Functional Requirements in a Smart Classroom System: A Paired Blind Study

Equipo **FGMMN** · Sánchez Cornejo, G. A. · Mendoza Palma, A. J. · Cedeño Ávila, W. D. · Muñoz Quiñónez, Y. E. · Gilces Carranza, J. I. ·
Docente: Ing. Gleiston Guerrero Ulloa

Contexto. Los Modelos Grandes de Lenguaje (LLM) se proponen cada vez más como apoyo a la elicitación de requisitos, pero pocos estudios los comparan contra requisitos elicitados por humanos a partir del mismo material fuente real.

Objetivo. Comparar, de forma pareada y ciega, la calidad de Requisitos Funcionales (RF) elicitados por el equipo humano frente a los generados por un LLM, a partir del mismo corpus de 10 entrevistas anónimas de un sistema real (SIGA), en 5 dimensiones de calidad.

Método. Cuasi-experimento apareado. 3 jueces ciegos calificaron 51 ítems (escala 1–5). Prueba t o Wilcoxon según normalidad, corrección de Holm-Bonferroni por las 5 comparaciones, tamaño del efecto (Cohen d / Cliff δ) con IC 95% por bootstrap (10 000 réplicas).

Resultados. El LLM puntúa igual o más alto que el humano en las 5 dimensiones, pero **ninguna diferencia sobrevive** la corrección de Holm-Bonferroni. Un cálculo de potencia post-hoc muestra que el panel de 3 jueces alcanza solo **8,4%** de potencia (se necesitarían 34 pares para el 80% convencional).

Conclusiones. Con el tamaño de muestra actual, el estudio **no puede confirmar ni descartar** una diferencia de calidad entre ambos orígenes de elicitación. Se declara esta limitación de forma explícita en lugar de sobre-interpretar la tendencia numérica favorable al LLM.

Resultados principales

Dimensión	Prueba	p (Holm)	Efecto (IC 95%)
Compleitud	t apareada	0.426	d=-1.04 [-2.12, 0.00]
Ausencia de ambigüedad	t apareada	0.222	d=-2.35 [-18.38, 0.00]
Verificabilidad	t apareada	0.380	d=-1.46 [-12.96, 0.00]
Corrección resp. fuente	Wilcoxon	0.500	δ =-0.56 [-1.00, 1.00]
Consistencia interna	t apareada	0.059	d=-5.27 [-42.72, 0.00]

Ninguna dimensión alcanza significancia tras la corrección ($\alpha=0,05$). Potencia real del diseño con n=3 jueces: 8,4%.

Recursos y trazabilidad

Repositorio GitHub	github.com/gsanchezc6-beep/SIGA_FGMMN_ISR401_AVANCE_2B
Registro OSF (protocolo)	doi.org/10.17605/OSF.IO/7PQ3H
Depósito Zenodo (paquete FAIR)	PENDIENTE tras el depósito
Revista/conferencia objetivo	REFSQ 2027 — track Posters & Tools
Licencia	Apache-2.0 (código) · CC BY 4.0 (datos y documentos)