

SIGA

Sistema Inteligente de Gestión de Aulas

Requisitos Funcionales elicitados por un analista humano frente a los generados por un LLM: un estudio pareado y ciego

Equipo FGMMN

Sánchez Cornejo, Gary Alberto · Muñoz Quiñónez, Yeranick Esther · Cedeño Ávila, Winston Damián
Universidad Técnica Estatal de Quevedo · ISR-401 Ingeniería de Requerimientos · Entrega 4 (2B)

Un sistema real, una pregunta concreta

SIGA tiene cliente identificable: la Facultad de Ciencias de la Computación de la UTEQ. No es un dominio ficticio de curso.

RQ1

¿Los Requisitos Funcionales que genera un LLM a partir del mismo material de entrevistas son comparables en calidad a los que elicitó un analista humano?

2

Comparación pareada y ciega

Mismo corpus de entrevistas para ambos orígenes, no un corpus distinto por brazo.

2

Pipeline 100% reproducible

Publicado junto con el paquete de datos completo (scripts + datos + resultados).

2

Transparencia metodológica

Se documentan dos complicaciones reales del estudio, no se ocultan.

Seis capacidades, tres perfiles de usuario reales

- Monitoreo ambiental en tiempo real
- Alertas de anomalías
- Gestión de mantenimiento
- Control remoto de equipos de aula
- Análisis predictivo de fallas
- Reportes administrativos

Perfiles entrevistados: docentes, coordinación académica, conserjería/infraestructura.

Volumen real de campo: 16 entrevistas, con los 3 perfiles bien representados.




Diagrama de contexto del sistema (extracto)

Cuasi-experimento apareado, ciego, pre-registrado

Diseño

Cuasi-experimento apareado y ciego, con 3 jueces independientes de las personas entrevistadas.

Instrumento

51 ítems evaluados en 5 dimensiones de calidad (completitud, ausencia de ambigüedad, verificabilidad, corrección respecto de la fuente, consistencia interna), escala 1–5.


Plan de análisis

Shapiro-Wilk para elegir prueba paramétrica o no paramétrica · corrección de Holm-Bonferroni por comparaciones múltiples · tamaño del efecto con IC 95% por bootstrap.

Pre-registro

OSF · DOI 10.17605/OSF.IO/7PQ3H — las desviaciones respecto del registro están documentadas explícitamente.

En las 5 dimensiones, el LLM iguala o supera al humano



Media/mediana por dimensión y origen (humano vs. LLM), 5 dimensiones de calidad, escala 1–5.

Cifras crudas favorables al LLM en las 5 dimensiones. Pero una diferencia favorable en los datos crudos no implica, por sí sola, significancia estadística — eso se revisa en el siguiente bloque.

Ninguna diferencia sobrevive la corrección múltiple

El caso más cercano a significancia: Consistencia interna

ANTES de corregir

$$p = 0,012$$

parecía estadísticamente significativo ($\alpha = 0,05$)




DESPUÉS de Holm-Bonferroni

$$p = 0,059$$

ya no es significativo

Ninguna de las 5 dimensiones sobrevive la corrección por comparaciones múltiples.

Efectos grandes, intervalos que cruzan el cero



8,4 %

potencia estadística real con $n = 3$ jueces (objetivo convencional: 80 %)

34 pares

de jueces serían necesarios para alcanzar el 80 % de potencia convencional

Efectos grandes en magnitud, pero los intervalos de confianza al 95 % cruzan el cero: esto es exactamente lo que se espera con una muestra tan pequeña.

La tendencia favorable al LLM no se sostiene aún

Es un ejemplo concreto de por qué la corrección por comparaciones múltiples y el cálculo de potencia importan — no un formalismo.

Interna

Panel de solo 3 jueces, potencia estadística muy baja.

Externa

Un solo dominio, un solo idioma, un solo modelo — no generaliza sola.

Constructo

El LLM tuvo exposición previa parcial al conjunto humano; su corpus fuente (11 entrevistas) ya no coincide exactamente con el del conjunto humano (10, tras excluir una por retiro de consentimiento).

Conclusión

Intervalos de confianza muy anchos por el tamaño de muestra pequeño.

RQ1 queda abierta — con honestidad, no con evasión

No se puede confirmar ni descartar una diferencia de calidad con el tamaño de muestra actual. Se declara así explícitamente, sin sobreinterpretar la tendencia numérica favorable al LLM.

Trabajo futuro concreto

- Ampliar el panel de jueces a 34, el n requerido por el cálculo de potencia.
- Re-generar los dos conjuntos sobre el corpus completo de 16 entrevistas.
- Ampliar la ronda terminal más allá del perfil docente.

Las 3 contribuciones del bloque 1 se sostienen con la evidencia ya mostrada.

Demostración en vivo del prototipo (MVP)

Entorno

npm install y npm start sobre Node 22.5. Es la vía verificada el 2026-08-29; el despliegue con Docker se declara sin probar en 05_MVP/README.md.

Alcance

Dos escenarios fijados de antemano: acceso por roles (RF-19) y cadena sensor → alerta → ticket (RF-01, RF-08, RF-11).

Credenciales

Únicamente las credenciales de demostración de 05_MVP/README.md. Nunca credenciales reales de personas del cliente.

Los dos escenarios se recorren sobre el entorno levantado con docker compose, no sobre capturas: lo que se ve es el sistema ejecutándose.

La especificación se inspeccionó con método, no se leyó por encima

Inspección de Fagan INS-01 — 16 defectos

3 críticos, 9 mayores, 4 menores. Densidad de 0,64 defectos por requisito funcional. Cinco roles repartidos entre tres personas; autor y moderador nunca coinciden.

Re-inspección REINS-01 — 15 cerrados, 1 residual

Cada defecto lo verifica quien no lo corrigió. El residual es DEF-06, la apertura individual de cámara.

Comité de control de cambios CCB-01 — 4 solicitudes

Tres aprobadas. SC-03 queda diferida porque no se verificó si la interfaz instalada expone el flujo de una cámara concreta.

Corrección = 1 residual / 25 RF = 0,04, frente a la referencia de 0,05. El margen es de un solo defecto, y lo decimos así.

El tablero dice lo mismo que la matriz, y se comprueba por script

Matriz de trazabilidad — 75 filas

41 con la cadena completa de fuente a criterio de aceptación. Las 75 tienen todos sus eslabones declarados: ninguna celda ambigua.

Tablero de gestión — 61 actividades

25 requisitos funcionales, 24 no funcionales y 12 restricciones de diseño, cada uno con su evidencia de origen, su historia y su caso de prueba.

Sincronización — 100 %

61 de 61. Ni un requisito sin actividad, ni una actividad sin requisito. Se recalcula con un script sobre el export del tablero.

Ese 100 % mide correspondencia entre dos listas, no avance: las sesenta y una actividades están en «Por hacer», que es su estado real.

N = 16 entrevistas, 10 sesiones de validación, 12 notas de campo

Corpus — 16 entrevistas transcritas y anonimizadas

Las dieciséis codificadas: 136 fragmentos bajo 50 códigos. Las seis últimas se codificaron el 6 de septiembre, repartidas por entrevista completa entre los tres.

Doble codificación — κ de Cohen 0,548 y 0,911


Dos integrantes codificaron por separado el mismo subconjunto. 0,548 a nivel de código (IC95 % [0,369 · 0,720]), acuerdo moderado; 0,911 a nivel de categoría (IC95 % [0,716 · 1,000]). Coincidimos en de qué trata el fragmento y discrepamos en el código exacto.

Validación — 10 walkthroughs, 3 con usuario técnico

Notas de campo manuscritas y contemporáneas en las seis últimas; reconstruidas y declaradas como tales en las seis de observación de entorno.

Lo que falta se dice en el propio documento. Una limitación declarada es evidencia; una limitación callada es un hallazgo del tribunal.

Tres integrantes, veinticinco minutos repartidos



Los tres superan el mínimo de cuatro minutos por integrante que fija la guía. El reparto sigue la contribución real que declara la matriz de aporte individual.

Gracias

Preguntas del tribunal — 10 min

OSF: [10.17605/OSF.IO/7PQ3H](https://osf.io/7PQ3H)

Repositorio: github.com/gsanchezc6-beep/SIGA_FGMMN_ISR401_AVANCE_2B