

SIGA

Sistema Inteligente de Gestión de Aulas

Requisitos Funcionales elicitados por un analista humano frente a los generados por un LLM: un estudio pareado y ciego

Equipo FGMMN

Sánchez Cornejo · Muñoz Quiñónez · Gilces Carranza · Mendoza Palma · Cedeño Ávila

Universidad Técnica Estatal de Quevedo · ISR-401 Ingeniería de Requerimientos · Entrega 4 (2B)

25 minutos, 7 bloques, cronómetro visible

1	Problema y contribuciones	3 min
2	El sistema y sus stakeholders	3 min
3	Metodología del componente empírico	4 min
4	Resultados	6 min
5	Discusión y amenazas a la validez	4 min
6	Conclusiones y trabajo futuro	3 min
7	Demostración del prototipo	2 min

+ 10 min de preguntas del tribunal

Un sistema real, una pregunta concreta

SIGA tiene cliente identificable: la Facultad de Ciencias de la Computación y Diseño Digital de la UTEQ. No es un dominio ficticio de curso.

RQ1

¿Los Requisitos Funcionales que genera un LLM a partir del mismo material de entrevistas son comparables en calidad a los que elicitó un analista humano?

1

Comparación pareada y ciega

Mismo corpus de entrevistas para ambos orígenes, no un corpus distinto por brazo.

2

Pipeline 100% reproducible

Publicado junto con el paquete de datos completo (scripts + datos + resultados).

3

Transparencia metodológica

Se documentan dos complicaciones reales del estudio, no se ocultan.

Seis capacidades, tres perfiles de usuario reales

- Monitoreo ambiental en tiempo real
- Alertas de anomalías
- Gestión de mantenimiento
- Control remoto de equipos de aula
- Análisis predictivo de fallas
- Reportes administrativos

Perfiles entrevistados: docentes, coordinación académica, conserjería/infraestructura.

Volumen real de campo: 10 entrevistas válidas, con los 3 perfiles bien representados.




Diagrama de contexto del sistema (extracto)

Cuasi-experimento apareado, ciego, pre-registrado

Diseño

Cuasi-experimento apareado y ciego, con 3 jueces independientes de las personas entrevistadas.

Instrumento

51 ítems evaluados en 5 dimensiones de calidad (completitud, ausencia de ambigüedad, verificabilidad, corrección respecto de la fuente, consistencia interna), escala 1–5.


Plan de análisis

Shapiro-Wilk para elegir prueba paramétrica o no paramétrica · corrección de Holm-Bonferroni por comparaciones múltiples · tamaño del efecto con IC 95% por bootstrap.

Pre-registro

OSF · DOI 10.17605/OSF.IO/7PQ3H — las desviaciones respecto del registro están documentadas explícitamente.

En las 5 dimensiones, el LLM iguala o supera al humano



Media/mediana por dimensión y origen (humano vs. LLM), 5 dimensiones de calidad, escala 1–5.

Cifras crudas favorables al LLM en las 5 dimensiones. Pero una diferencia favorable en los datos crudos no implica, por sí sola, significancia estadística — eso se revisa en el siguiente bloque.

Ninguna diferencia sobrevive la corrección múltiple

El caso más cercano a significancia: Consistencia interna

ANTES de corregir

$$p = 0,012$$

parecía estadísticamente significativo ($\alpha = 0,05$)




DESPUÉS de Holm-Bonferroni

$$p = 0,059$$

ya no es significativo

Ninguna de las 5 dimensiones sobrevive la corrección por comparaciones múltiples.

Efectos grandes, intervalos que cruzan el cero



8,4 %

potencia estadística real con $n = 3$ jueces (objetivo convencional: 80 %)

34 pares

de jueces serían necesarios para alcanzar el 80 % de potencia convencional

Efectos grandes en magnitud, pero los intervalos de confianza al 95 % cruzan el cero: esto es exactamente lo que se espera con una muestra tan pequeña.

La tendencia favorable al LLM no se sostiene aún

Es un ejemplo concreto de por qué la corrección por comparaciones múltiples y el cálculo de potencia importan — no un formalismo.

Interna

Panel de solo 3 jueces, potencia estadística muy baja.

Externa

Un solo dominio, un solo idioma, un solo modelo — no generaliza sola.

Constructo

El LLM tuvo exposición previa parcial al conjunto humano; su corpus fuente (11 entrevistas) ya no coincide exactamente con el del conjunto humano (10, tras excluir una por retiro de consentimiento).

Conclusión

Intervalos de confianza muy anchos por el tamaño de muestra pequeño.

RQ1 queda abierta — con honestidad, no con evasión

No se puede confirmar ni descartar una diferencia de calidad con el tamaño de muestra actual. Se declara así explícitamente, sin sobreinterpretar la tendencia numérica favorable al LLM.

Trabajo futuro concreto

- Ampliar el panel de jueces a 34, el n requerido por el cálculo de potencia.
- Re-generar el Conjunto A del LLM sobre el corpus corregido de 10 entrevistas.
- Aplicar codificación axial y recalcular la curva de saturación temática.

Las 3 contribuciones del bloque 1 se sostienen con la evidencia ya mostrada.

Demostración en vivo del prototipo (MVP)

Entorno

docker compose up — entorno estable ya verificado antes de la defensa.

Alcance


Dos escenarios de la matriz de trazabilidad, identificados de antemano.

Credenciales

Únicamente las credenciales de demostración de 05_MVP/README.md. Nunca credenciales reales de personas del cliente.

Falla total de la demostración $\Rightarrow$ C13 = 0. Practicar el flujo exacto antes, con la red ya verificada.

Reparto de tiempos — ajustar antes de la semana 16



Gilces no participa en el reparto: no aportó al trabajo real, y la defensa evalúa capacidad individual. Muñoz queda con 3 min, por debajo del mínimo — ampliar su bloque 6 antes del simulacro. Validar todo con cronómetro real.

Gracias

Preguntas del tribunal — 10 min

OSF: [10.17605/OSF.IO/7PQ3H](https://osf.io/7PQ3H)

Repositorio: github.com/gsanchezc6-beep/SIGA_FGMMN_ISR401_AVANCE_2B